


## سوال ۱: سوالات آماری (پیاپی سازی)

### \*\*\* بخش ۱: مسئله منشی

#### سوال ۱- بدست آوردن مناسب ترین مقدار $k$ برای تعداد کاندیدای ثابت

ابتدا برای الگوریتم راه حل مسئله، تابعی با نام `find_Pr()` می‌نویسیم. این تابع در حقیقت تعداد آزمایش ها، مقادیر  $n$  و  $k$  را می‌گیرد و در نهایت احتمال را برای مقادیر  $n$  و  $k$  برمی‌گرداند. در این سوال مقدار  $n$  را به صورت ثابت  $n = 100$  در نظر می‌گیریم و مقدار  $k$  را به صورت  $k = \text{range}(5, 101, 5)$  تعریف می‌کنیم. در نهایت نیز به ازای مقادیر  $k$ ، احتمالات آن را با استفاده از `scatter plot` رسم می‌کنیم. تصویر ۱-۱ این نمودار را نشان می‌دهد. همانطور که مشاهده می‌شود، بهترین مقدار  $k$  تقریباً در حدود ۳۰ تا ۴۰ می‌باشد. (در سوال ۳، ثابت می‌شود که بهترین مقدار  $k$  برابر  $k = \frac{n}{e} = \frac{100}{e} \cong 36.78$  با احتمال  $Pr = \frac{1}{e} = 0.3678$  خواهد بود.)

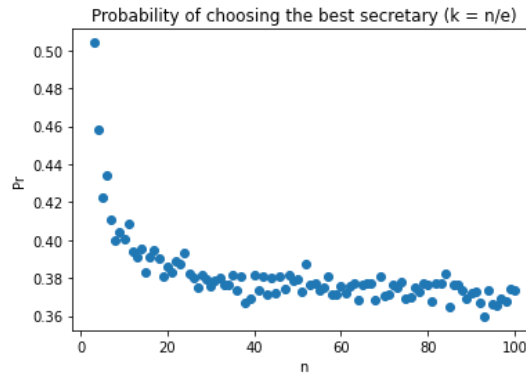


تصویر ۱-۱: نمودار احتمال انتخاب بهترین کاندید برحسب مقادیر  $k$

#### سوال ۲- بدست آوردن احتمال انتخاب بهترین کاندید به ازای $k = \frac{n}{e}$

در این سوال مقادیر  $n$  را از ۳ تا ۱۰۰ متغیر و به صورت  $n = \text{range}(3, 100)$  و مقدار  $k$  را به صورت  $k = \frac{n}{e}$  در نظر می‌گیریم. در نهایت به ازای مقادیر  $n$ ، احتمالات آن را با استفاده از `scatter plot` رسم می‌کنیم. تصویر ۲-۱ این نمودار را

نشان می‌دهد. همانطور که مشاهده می‌شود با افزایش مقدار  $n$  احتمال انتخاب بهترین کاندید کاهش می‌یابد اما به ازای  $n$  های بزرگ تقریباً احتمال ثابت و برابر  $\frac{1}{e} = 0.3678$  می‌ماند.



تصویر ۱-۲: نمودار احتمال انتخاب بهترین کاندید برحسب مقادیر  $n$

### سوال ۳- بدست آوردن احتمال انتخاب بهترین کاندید (تحلیلی)

برای حل این مسئله از احتمال شرطی استفاده می‌کنیم. در حقیقت ما می‌خواهیم احتمال انتخاب بهترین کاندید از بین  $n - k$  کاندید بعد از  $k$  کاندید اول را بدست آوریم.

$$\begin{aligned} Pr(k \text{ مرز } \text{بهترین کاندید با مرز } k) &= \sum_{i=1}^n Pr(\text{کاندید } i \text{م انتخاب شود} \cap \text{کاندید } i \text{م بهترین باشد}) \\ &= \sum_{i=1}^n Pr(\text{کاندید } i \text{م بهترین باشد} \mid \text{کاندید } i \text{م انتخاب شود}) \cdot Pr(\text{کاندید } i \text{م بهترین باشد}) \end{aligned}$$

با توجه به اینکه اگر بهترین کاندید بین  $k - 1$  نفر اول باشد، احتمال انتخاب آن صفر است یعنی:

$$\sum_{i=1}^{k-1} Pr(\text{کاندید } i \text{م بهترین باشد} \mid \text{کاندید } i \text{م انتخاب شود}) = 0$$

به عبارت دیگر می‌توانیم بگوییم، کاندید  $i$  ام باید فقط بهتر از بهترین کاندید بین  $k - 1$  کاندید اول باشد (یعنی بهترین کاندید بین  $i - 1$  کاندید اول و  $k - 1$  کاندید اول یکی باشد). پس اگر  $A_{k,i}$  را به صورت زیر تعریف کنیم.

بهترین کاندید  $i - 1$  کاندید اول همان بهترین کاندید بین  $k - 1$  کاندید اول باشد  $A_{k,i}$

$$\begin{aligned} Pr(\text{انتخاب بهترین کاندید}) &= \sum_{i=k}^n \underbrace{Pr(A_{k,i} \mid \text{کاندید } i \text{م بهترین باشد})}_{\frac{\binom{k-1}{1}}{\binom{i-1}{1}} = \frac{k-1}{i-1}} \cdot \underbrace{Pr(\text{کاندید } i \text{م بهترین باشد})}_{\frac{1}{n}} = \frac{1}{n} \sum_{i=r}^n \frac{k-1}{i-1} \\ &\rightarrow Pr(k) = \frac{k-1}{n} \sum_{i=r}^n \frac{1}{i-1} \end{aligned}$$

در حالت  $n \rightarrow \infty$ ، احتمال پیوسته به صورت زیر تعریف می‌شود.

$$Pr(k) = \lim_{n \rightarrow \infty} \frac{k-1}{n} \sum_{i=k}^n \frac{1}{i-1} \xrightarrow{\frac{k}{n}=x} Pr(x) = x \int_x^1 \frac{1}{t} dt = -x \ln(x) \rightarrow P(x) = -x \ln(x)$$

حال می‌خواهیم ببینیم به ازای چه مقدار  $x$  احتمال  $P(x)$  ماکزیمم می‌شود.

$$\frac{d}{dx} P(x) = \frac{d}{dx} (-x \ln(x)) = -\ln x - 1 = 0 \rightarrow \ln(x) = -1 \rightarrow x^{opt} = \frac{1}{e}$$

$$x = \frac{k}{n} \rightarrow k^{opt} = n x^{opt} = \frac{n}{e} \rightarrow k^{opt} = \frac{n}{e}$$

### \*\*\* بخش ۲: بررسی قضیه حد مرکزی

**قضیه حد مرکزی:** دنباله  $X_1, X_2, \dots, X_n$  از متغیرهای تصادفی مستقل با توزیع یکنواخت پیوسته  $D$  را که بر یک فضای

احتمال تعریف شده‌اند، در نظر بگیرید. فرض کنید میانگین  $D$  برابر  $\mu$  و انحراف معیار از آن  $\sigma$  است. حالا سری میانگین  $S_n$

را به صورت  $S_n = X_1 + X_2 + \dots + X_n$  در نظر بگیرید. در این صورت میانگین  $S_n$  برابر  $\mu$  و انحراف معیار از آن  $\frac{\sigma}{\sqrt{n}}$  (واریانس

$\frac{\sigma^2}{n}$ ) و براساس قضیه حد مرکزی  $S_n$  در بی‌نهایت به توزیع نرمال  $\mathcal{N}(\mu, \frac{\sigma^2}{n})$  میل می‌کند.

در این بخش می‌خواهیم با استفاده از توزیع اولیه  $X$ ، دنباله  $X_1, X_2, \dots, X_n$  را تعریف کرده و از هر عضو این دنباله میانگین


بگیریم و توزیع  $S_n$  را بدست آوریم. در این صورت انتظار داریم طبق قضیه حد مرکزی  $S_n$  در بی‌نهایت به توزیع نرمال  $\mathcal{N}(\mu, \frac{\sigma^2}{n})$

میل کند.

ابتدا ارقام ۳۶۹ را به تابع `Distribution()` می‌دهیم. در نهایت با استفاده از تابع `Dist()` که برای به دست آوردن میانگین هر


مرحله ( $s$  مرحله) با استفاده از  $n$  نمونه نوشته شده است (بدست آوردن  $S_n$ )، توزیع جمعیت را به همراه میانگین و واریانس آن

مطابق با تصویر ۱-۳ نشان می‌دهیم. همانطور که مشاهده می‌شود توزیع شکل نرمال پیدا کرده است.



تصویر ۱-۳: توزیع میانگین نمونه‌های جمعیت ( $s = 1000$  و  $n = 1000$ )


حال فایل پیوست شده در تمرین با عنوان wine.csv را در پایتون می‌خوانیم و توزیع ستون ۱۲ آنرا مطابق با تصویر ۴-۱ نشان می‌دهیم. همانطور که مشاهده می‌شود این توزیع در ابتدا نرمال نیست.



تصویر ۴-۱: توزیع داده wine

حال با استفاده از تابع  $\text{Dist}()$  به ازای مقادیر مختلف  $n$  از داده‌ها نمونه می‌گیریم تا توزیع‌های مستقل بسازیم و در نهایت از آن‌ها در ۱۰۰۰ بار تکرار میانگین می‌گیریم. تصویر ۵-۱ نمودار توزیع‌های گفته شده به ازای  $n$ ‌های مختلف را نشان می‌دهد.

Wine distribution for the  $n$  different values ( $s = 1000$ )



تصویر ۵-۱: توزیع میانگین نمونه‌های wine ( $s = 1000$  و  $n$ ‌های مختلف)

همانطور که در تصویر ۵-۱ نیز مشاهده می‌شود، توزیع میانگین نمونه‌ها نرمال شده است و میانگین آن به ازای همه  $n$ ‌ها شکل نرمال دارد. همچنین مشاهده می‌شود که واریانس با افزایش  $n$  نزولی است. به این منظور مطابق با تصویر ۶-۱ میانگین و واریانس توزیع‌ها به ازای  $n$ ‌های مختلف نشان می‌دهیم. همانطور که مشاهده می‌شود رابطه  $\sigma_{new}^2 = \frac{\sigma^2}{n}$  کاملاً برقرار است.

```

Central Limit Theorem Analysis:
n = 10:      mean = 2.598, variance = 0.04849
CLT:        mean = 2.612, variance = 0.05013
n = 20:      mean = 2.615, variance = 0.02041
CLT:        mean = 2.612, variance = 0.02506
n = 30:      mean = 2.612, variance = 0.01391
CLT:        mean = 2.612, variance = 0.01671
n = 40:      mean = 2.616, variance = 0.00994
CLT:        mean = 2.612, variance = 0.01253
n = 50:      mean = 2.612, variance = 0.00716
CLT:        mean = 2.612, variance = 0.01003
n = 60:      mean = 2.612, variance = 0.00575
CLT:        mean = 2.612, variance = 0.00835
n = 70:      mean = 2.615, variance = 0.00434
CLT:        mean = 2.612, variance = 0.00716
n = 80:      mean = 2.614, variance = 0.00337
CLT:        mean = 2.612, variance = 0.00627
n = 90:      mean = 2.608, variance = 0.00292
CLT:        mean = 2.612, variance = 0.00557
n = 100:     mean = 2.612, variance = 0.00204
CLT:        mean = 2.612, variance = 0.00501
n = 110:     mean = 2.612, variance = 0.00161
CLT:        mean = 2.612, variance = 0.00456
n = 120:     mean = 2.613, variance = 0.00134
CLT:        mean = 2.612, variance = 0.00418
n = 130:     mean = 2.612, variance = 0.001
CLT:        mean = 2.612, variance = 0.00386
n = 140:     mean = 2.611, variance = 0.00075
CLT:        mean = 2.612, variance = 0.00358
n = 150:     mean = 2.611, variance = 0.00053
CLT:        mean = 2.612, variance = 0.00334

```

تصویر ۱-۶: میانگین و واریانس توزیع میانگین نمونه‌های *wine* ( $s = 1000$  و  $n$  های مختلف)

**سوال ۲: سوالات آماری (تحلیلی)****\*\*\* بخش ۱: فرض استقلال در بیز ساده انگارانه**

تعریف استقلال: اگر دو متغیر تصادفی مستقل باشند، رابطه زیر بین چگالی توام آن‌ها برقرار است.

$$f_{XY}(x, y) = f_X(x)f_Y(y) \rightarrow X \text{ and } Y \text{ are independent}$$

ناهمبستگی: در صورتی که ضریب همبستگی دو متغیر تصادفی که به صورت زیر تعریف می‌شود، صفر باشد، این دو متغیر ناهمبسته هستند.

$$\rho = E \left[ \frac{(X - E(X))}{\sqrt{E[(X - E(X))^2]}} \frac{(Y - E(Y))}{\sqrt{E[(Y - E(Y))^2]}} \right] = 0 \rightarrow X \text{ and } Y \text{ are uncorrelated}$$

تعامد: تعامد مفهومی جبری است که در آمار و احتمالات با همان ناهمبستگی مدل می‌شود.

حال باید به دو نکته توجه می‌کنیم:

۱- استقلال دو متغیر تصادفی ناهمبسته بودن آن‌ها را نشان می‌دهد.

۲- ناهمبسته بودن دو متغیر تصادفی لزوماً استقلال آن‌ها را نتیجه نمی‌دهد.

← در فضای اولیه ویژگی‌ها مستقل نیستند. در فضای جدید ویژگی‌ها متعامد و ناهمبسته اند اما الزامی وجود ندارد که در این فضا ویژگی‌ها مستقل باشند. در نتیجه فرض بیز ساده انگارانه در فضای جدید نیز صحیح نیست و استدلال احمد اشتباه است.

**\*\*\* بخش ۲: محاسبه پارامترهای نمونه‌های  $i.i.d$  توزیع نرمال با استفاده از  $MLE$** 

تخمین Maximum Likelihood این مسئله به صورت زیر تعریف می‌شود.

$$i.i.d \text{ variables} \rightarrow (X_1, X_2, \dots, X_n)$$

$$\Rightarrow f_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = f_{X_1}(x_1)f_{X_2}(x_2) \dots f_{X_n}(x_n)$$

$$\Rightarrow f_{X_1, X_2, \dots, X_n|\theta}(x_1, x_2, \dots, x_n|\theta) = \prod_{i=1}^n f_{X_i}(x_i|\theta) = \mathcal{L}(\theta)$$

$$\hat{\theta}_{ML} = \max_{\theta} \mathcal{L}(\theta) = \max_{\theta} \prod_{i=1}^n f_{X_i}(x_i|\theta)$$

که برای بدست آوردن  $\hat{\theta}_{ML}$  در این بخش، مشتق  $\mathcal{L}(\theta)$  بر حسب  $\theta$  را صفر قرار می‌دهیم. برای سادگی محاسبات مشتق‌ها از لگاریتم طبیعی  $\mathcal{L}(\theta)$  (که آن را به صورت  $\mathcal{LL}(\theta)$  تعریف می‌کنیم) استفاده می‌کنیم.

در این بخش می‌خواهیم پارامترهای توزیع نرمال یعنی میانگین و واریانس را بدست آوریم. به این منظور یک‌بار به جای  $\theta$  میانگین و بار دیگر واریانس قرار دهیم.

$$X_i \sim \mathcal{N}(\mu, \sigma) \rightarrow f_{X_i}(x_i|\theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

$$\mathcal{L}(\mu, \sigma) = \prod_{i=1}^n f_{X_i}(x_i|\theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

$$\begin{aligned} \mathcal{LL}(\mu, \sigma) &= \ln \left( \prod_{i=1}^n f_{X_i}(x_i|\theta) \right) = \sum_{i=1}^n \ln \left( \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} \right) \\ &= \sum_{i=1}^n \left( -\ln(\sqrt{2\pi}\sigma) - \frac{(x_i - \mu)^2}{2\sigma^2} \right) \end{aligned}$$

$$\hat{\mu}_{ML}: \frac{\partial \mathcal{LL}(\mu, \sigma)}{\partial \mu} = 0 \rightarrow \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \hat{\mu}_{ML}) = 0 \rightarrow \hat{\mu}_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\hat{\sigma}_{ML}: \frac{\partial \mathcal{LL}(\mu, \sigma)}{\partial \sigma} = 0 \rightarrow \sum_{i=1}^n \left( -\frac{1}{\sigma} + \frac{(x_i - \mu)^2}{\sigma^3} \right) = 0 \rightarrow \hat{\sigma}_{ML} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

## سوال ۳: بیز ساده‌انگارانه

در این قسمت ابتدا در خصوص طبقه‌بند بیز ساده‌انگارانه توضیحات مختصری می‌دهیم. (برای این توضیحات از یک ویدیو که با لینک زیر استفاده می‌کنیم.)

- <https://www.youtube.com/watch?v=Po6lsacF5pw>

## \*\*\* طبقه‌بند بیز ساده‌انگارانه (Naïve Bayes Classifier) :

در بیز ساده‌انگارانه، هدف استفاده از قضیه بیز در طبقه‌بندی داده‌ها است. قضیه بیز به صورت زیر تعریف می‌شود.

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

حال در طبقه‌بندی داده‌ها، به فرض اگر داده  $X$  را به ما داده باشند، احتمال اینکه  $X$  در هر کدام از کلاس‌ها باشد را بدست آورده و با استفاده از بیشترین احتمال، کلاس داده  $X$  را مشخص می‌کنیم.

کلاس‌ها به صورت  $C_i$  و داده‌های هر ویژگی به صورت  $x_i$  مشخص می‌شود (فرض می‌کنیم  $d$  ویژگی متمایز داریم).

دو فرض در بیز ساده‌انگارانه که حائز اهمیت است به صورت زیر می‌باشد:

۱- داده‌ها در هر کلاس (برای هر ویژگی) از توزیع نرمال پیروی می‌کنند.

۲- داده‌های هر دو ویژگی متفاوت ناهمبسته‌اند.

احتمال اینکه داده  $X$  عضو کلاس  $C_i$  باشد به صورت زیر است.

$$P(C_i|X) = \frac{P(C_i)P(X|C_i)}{P(X)}$$

با توجه به ثابت بودن  $P(X)$  و اینکه می‌خواهیم مقایسه بین احتمال‌های کلاس‌های مختلف انجام دهیم، از مخرج صرف نظر می‌کنیم.

$$P(C_i|X) \propto P(C_i)P(X|C_i)$$

به  $P(C_i)$  احتمال پیشین (Prior) گفته می‌شود. برای بدست آوردن این احتمال صرفاً تعداد لیبل‌های کلاس  $C_i$  بر تعداد کل داده‌ها تقسیم می‌کنیم. (در داده‌های آموزش این احتمال را بدست می‌آوریم.)

به  $P(X|C_i)$  احتمال راستی آزمایی (Likelihood) گفته می‌شود. برای به دست آوردن این احتمال از دو فرض گفته شده استفاده می‌کنیم.

$$\text{Independent Features} \rightarrow P(X|C_i) = P(x_1|C_i)P(x_2|C_i) \dots P(x_d|C_i)$$



$$P(x_j|C_i) \text{ has a normal (gaussian) distribution} \rightarrow P(x_j|C_i) = \frac{1}{\sigma_{x_j}\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_j-\mu_{x_j}}{\sigma_{x_j}}\right)^2}$$

که با استفاده از داده‌های آموزش باید توزیع همه  $P(x_j|C_i)$  را بدست آوریم. یعنی پارامترهای  $\sigma_{x_j}$  را مشخص کنیم.  
در نهایت برای داده‌های تست احتمال تعلق کلاس‌ها به صورت زیر بدست می‌آید.

$$P(C_i|X) \equiv P(C_i)P(x_1|C_i)P(x_2|C_i) \dots P(x_d|C_i)$$

$$P(x_j|C_i) = \frac{1}{\sigma_{x_j}\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_j-\mu_{x_j}}{\sigma_{x_j}}\right)^2}$$

### سوال ۱. معرفی ویژگی‌ها و نحوه بدست آوردن احتمال‌ها

حال می‌خواهیم برای مسئله اشاره شده، طبقه بند بیز ساده انگارانه طراحی کنیم.  
به این منظور در ابتدا ویژگی‌ها را به صورت زیر بدست می‌آوریم.

ویژگی ۱: ارتفاع عدد (Height)

ویژگی ۲: پهنای عدد (Width)

ویژگی ۳: تعداد # نیمه بالایی عدد (Sharp\_num\_upper) - برای اعداد {5,7,9} این مقدار بزرگتر است.

ویژگی ۴: تعداد + نیمه بالایی عدد (Plus\_num\_upper) - برای اعداد {5,7,9} این مقدار بزرگتر است.

ویژگی ۵: تعداد # نیمه پایینی عدد (Sharp\_num\_below) - برای اعداد {2,4,6} این مقدار بزرگتر است.

ویژگی ۶: تعداد + نیمه پایینی عدد (Plus\_num\_below) - برای اعداد {2,4,6} این مقدار بزرگتر است.

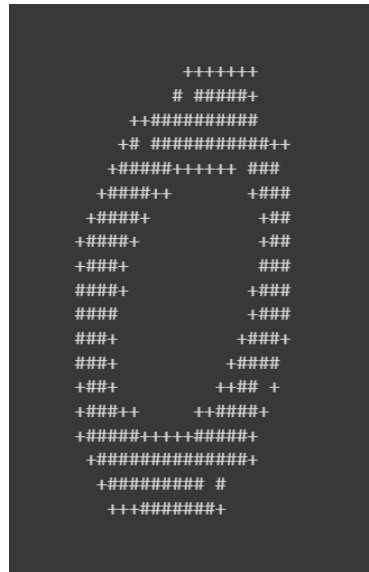
ویژگی ۷: بزرگترین نسبت تعداد # و + به فضا‌های خالی در سطرها‌ی عکس‌ها (Row\_limit) - تشخیص {1,7,4,5}

حال برای بدست آوردن احتمال‌های پسین هر کلاس و مقایسه احتمال‌ها و تشخیص کلاس داده‌های تست مطابق با توضیحات داده شده برای طبقه بند Naïve Bayes عمل می‌کنیم.

برای فرآیند آموزش تابع Training() نوشته شده است که در آن برای استخراج ویژگی‌ها از تابع Feature\_Extraction() استفاده شده است.

همچنین برای طبقه بندی و فرآیند ارزیابی تابع Validation() نوشته شده است.

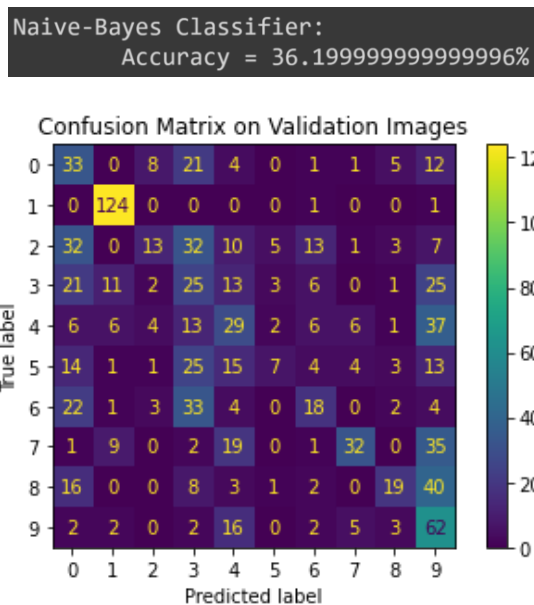
تصویر ۱-۳، یک تصویر تصادفی از دادگان را نشان می‌دهد.



تصویر ۳-۱: یک تصویر تصادفی از دادگان آموزشی

## سوال ۲. بدست آوردن درصد دقت تشخیص اعداد

درصد دقت تشخیص اعداد برای الگوریتم گفته شده روی داده های ارزیابی (Validation) به همراه ماتریس آشفتگی (Confusion Matrix) در تصویر ۳-۲ قابل مشاهده است.



تصویر ۳-۲: دقت و ماتریس آشفتگی طبقه بند بیز ساده‌انگارانه